

# Skin Lesion Segmentation

Autores: Pedro Lucas Damasceno Silva, Robson Novato Lobão, Augusto Ferreira Guillarducci

Orientador: Guillermo Cámara Chávez

15 de março de 2023

## 1 Introdução

A segmentação de lesões dermatológicas é de suma importância para a identificação de doenças cutâneas, como, por exemplo, o melanoma. Todavia, realizá-la de forma automática para que sejam utilizadas por sistemas computadorizados de diagnóstico ainda é um desafio, haja vista a ampla possibilidade de variação das imagens (lesões de diferentes formas, casos onde há baixo contraste, presença de artefatos, angulação, entre outras). Dessarte, o tema se tornou objeto de inúmeros estudos interdisciplinares, com ênfase para áreas de processamento de imagens e inteligência artificial.

Nessa revisão bibliográfica, foram enunciados alguns dos artigos mais relevantes da atualidade (partindo de 2017) que propõem métodos de segmentação baseados, em sua maioria, em redes neurais convolucionais profundas. Essas redes permitem a extração de características complexas das imagens de lesões de pele e têm apresentado resultados promissores na segmentação precisa de lesões de pele. Nesta revisão bibliográfica, apresentamos uma análise crítica das técnicas de segmentação de lesões de pele mais recentes e suas aplicações na prática clínica, bem como discutimos as limitações e desafios associados a essas técnicas.

## 2 Revisão Bibliográfica

### 2.1 Skin lesion segmentation in dermoscopy images via deep full resolution convolutional networks (AL-MASNI et al., 2018)

A segmentação automática de lesões de pele em imagens de dermatoscopia é um pré-requisito de suma importância para o desenvolvimento de sistemas capazes de diagnosticar casos de melanoma. Todavia, devido à irregularidade das formas, casos onde há baixo contraste e várias outras variáveis, definir e segmentar as lesões continua a ser um desafio para a ciência. O artigo em questão propõe um método baseado em redes neurais convolucionais, que dispensa operações de pré ou pós-processamento ou revisão posterior das margens da lesão. A performance de segmentação do método desenvolvido foi comparada com outras abordagens que utilizam deep learning (FCN, U-Net, SegNet) e apresentou boas margens de vantagem, tanto em relação ao índice de Jaccard quanto à acurácia da segmentação.

O FRCN (Full Resolution Convolutional Networks) elimina as camadas de subamostragem da arquitetura tradicional de CNN (Convolutional Neural Network), o que preserva as características individuais dos pixels de input. Cada pixel da imagem tem suas características extraídas usando as camadas convolucionais (16, no total). As 3 últimas camadas da rede neural, completamente conectadas, foram substituídas pelas camadas convolucionais. Ademais, outras adaptações também foram feitas para ajustar o peso dos modelos durante o treinamento, como, por exemplo, a perda H de cada pixel (compensada através do cálculo de cross-entropy

loss entre a anotação fundamental e o mapa segmentado previsto).

Aplicações de redes neurais em áreas médicas ainda sofrem com a escassez de amostragem devido à complexidade e custo de identificação durante a aquisição dos dados. Para compensar, estratégias de expansão dos data sets e transfer learning foram empregadas durante as etapas de treinamento e testagem. O tempo computacional durante o treinamento foi de 17.5h, porém a decodificação de apenas uma imagem de dermatoscopia tomou 9.7 segundos. Dado o tempo razoável, é possível afirmar a aplicação do método para práticas clínicas.

Os resultados mostram que o FRCN supera o estado da arte em termos de precisão e sensibilidade. Além disso, o método desenvolvido é capaz de segmentar efetivamente diferentes tipos de lesões cutâneas, como melanoma e queratose. Todavia, o método proposto foi avaliado em um conjunto de dados específico, o que pode limitar sua generalização para outros conjuntos de dados. Além disso, ele pode não funcionar tão bem em imagens de lesões cutâneas em outras partes do corpo, com exceção da pele. Por fim, o método é baseado em aprendizado supervisionado, o que significa que depende de um grande conjunto de dados rotulados para treinamento. O processo de rotulação de dados pode ser custoso, e a falta de dados rotulados, comum no âmbito médico, pode levar a um desempenho insuficiente da rede neural.

## 2.2 Skin Lesion Segmentation in Dermoscopic Images with Combination of YOLO and GrabCut Algorithm (ÜNVER; AYAN, 2019)

O artigo propõe um método para segmentação de lesões dermatológicas que combina o You Only Look Once (YOLO), que utiliza uma única rede neural convolucional para identificar as margens da área de interesse na imagem, com o algoritmo GrabCut, que segmenta imagens baseado em cortes em grafos de acordo com áreas de interesse descritas pelo usuário.

Primeiramente, são removidos os artefatos da imagem. Em seguida, a região de interesse é detectada pelo YOLO, que possui alta eficiência. Neste passo, o YOLO é treinado em um conjunto de dados de dermatoscopia e, em seguida, usado para prever a localização da lesão na imagem. Em sequência, a área de interesse é extraída da imagem original e usada para obter uma área de interesse menor, contendo apenas a lesão. Isso reduz a complexidade computacional do método e concentra a análise na área de interesse. Depois, o GrabCut realiza a segmentação com base no resultado da operação anterior. Por fim, a imagem segmentada é suavizada usando uma operação de fechamento morfológico para remover possíveis pequenos buracos e lacunas na lesão.

Assim como o FRCN (AL-MASNI et al., 2018), o método em questão também foi avaliado com uso das base de dados ISBI 2016, PH2 e ISBI 2017. Com resultados ligeiramente superiores, o YOLO/GrabCut atingiu acurácia de segmentação de 95.51% e 94.24% no primeiro e segundo data-set, e 94.9% no terceiro. Dessarte, os resultados experimentais mostram que o método proposto supera os métodos de segmentação de lesões de pele existentes em termos de precisão e tempo de execução.

Embora o método proposto tenha mostrado resultados promissores, ainda existem algumas limitações e desafios a serem considerados. Por exemplo, o método depende da precisão da detecção da região de interesse pelo algoritmo YOLO, o que pode levar a erros de segmentação se a detecção for imprecisa. Além disso, a segmentação com o algoritmo GrabCut é sensível à qualidade da imagem e à escolha inicial das áreas de interesse.

## 2.3 Automatic Skin Lesion Segmentation Using Deep, Fully Convolutional Networks with Jaccard Distance (YUAN; CHAO; LO, 2017)

Fundamentado em pesquisas que buscam identificar melanomas em estado inicial em pacientes, o artigo de Yuan et al justifica a importância do seu artigo frisando o fato de que, reconhecido precocemente as porcentagens de mortes caem drasticamente de 95% para 15%, entretanto cita desafios para o reconhecimento das mesmas lesões em escalas menores, como por exemplo: (1) tamanho variável, (2) bordas borradas e irregulares, (3) pouco contraste entre a pele do paciente e as lesões.


Com relação a estudos passados e o que já tínhamos com relação ao reconhecimento de fronteiras de melanomas, esse artigo inovou em três principais aspectos, apresentaram um método totalmente automatizado para segmentação de lesões cutâneas, aproveitando o poder discriminativo de um FCN profundo de 19 camadas, utilizaram redes neurais profundas para resolver esse problema, um dos primeiros a fazerem a utilização dessa forma. Avaliaram extensivamente a eficácia, eficiência e capacidade de generalização do modelo proposto usando dois grandes bancos de dados. Por fim, projetaram uma função de perda apropriada que lida naturalmente com o desequilíbrio lesão-fundo da classificação pixel a pixel para segmentação de imagens médicas.

O foco principal do artigo, que é a apresentação do FCN, mostra seu funcionamento da seguinte forma: descreve o treinamento de uma Rede Neural Convolutiva (FCN) que mapeia uma entrada RGB para um mapa de probabilidade posterior. A rede contém 19 camadas, com 290.129 parâmetros ajustáveis e utiliza unidades lineares retificadas (ReLU) como função de ativação para cada camada convolutiva/deconvolutiva. A classificação é realizada em nível de pixel e a FCN funciona como um filtro que projeta a imagem de entrada em um mapa em que cada elemento representa a probabilidade de que o pixel correspondente pertença ao tumor. A função de ativação usada na camada de saída é a função sigmóide. Depois disso há o treinamento do FCN com algumas databases.

Os resultados se mostraram deveras efetivos para o banco de dados que tinham, entretanto carecem em alguns pontos, como: subsegmentação e supersegmentação de lesões, e baixo contraste nas imagens. Locais que podem ser atacados em estudos futuros.

## 2.4 Efficient skin lesion segmentation using separable-Unet with stochastic weight averaging (TANG et al., 2019)

Os autores motivam a pesquisa da mesma forma que o anterior, alegando ajudar no diagnóstico médico e evitando progressão da doença, o método utilizado se assemelha com anterior: usando um método de segmentação de lesões de pele (SLS) baseado na estrutura Separable-Unet com média ponderada estocástica. O método proposto aproveita a combinação de blocos convolucionais separáveis e arquiteturas U-Net, permitindo capturar características de contexto e informações semânticas para melhorar a capacidade de representação discriminativa em nível de pixel de redes convolucionais totalmente convolucionais (FCN). Além disso, para lidar com o problema de sobreajuste, é introduzido um esquema baseado em média ponderada estocástica que pode obter uma solução mais ampla e uma melhor generalização.



Uma forma de melhorar o modelo citado anteriormente, descrito pelos próprios autores é diminuir a perda das seguintes formas: (1) treinar o modelo com uma taxa de aprendizado cíclica e, em seguida, fazer a média de vários pontos de peso no final de cada ciclo, que são vistos como diferentes pontos ótimos locais (2) treinar o modelo com uma taxa de aprendizado constante pequena e, em seguida, fazer a média dos últimos vários pontos de peso. O conceito é apresentado em um mapa mostrando a diferença entre a aprendizagem padrão e o esquema de média ponderada estocástica. Esses dois métodos são utilizados após o modelo ter alcançado um estado de convergência estável. Uma diferença importante em relação ao primeiro citado é a presença de pós e pré processamento, aumentando o tempo de análise de uma imagem.

Outro ponto negativo, também citado pelo autor é a ausência de flexibilidade do modelo, se tornando inviável fazer a análise de qualquer outra lesão na pele que não possua características extremamente similares ao melanoma.

## 2.5 Skin Lesion Segmentation in Dermoscopic Images With Ensemble Deep Learning Methods (GOYAL et al., 2019)

O artigo frisa a limitação de dados de segmentação de lesões de pele precisos e confiáveis e propõe métodos de aprendizado profundo para melhorar a sensibilidade e especificidade na segmentação da borda da lesão. Os métodos de ensembles são treinados com base em Mask R-CNN e DeeplabV3+ em conjuntos de treinamento de segmentação ISIC-2017 e avaliados em conjuntos de teste ISIC-2017 e PH2. Os resultados mostram que os métodos propostos superaram outros métodos de segmentação, incluindo FrCN, FCNs, U-Net e SegNet.

A especificidade também foi avaliada em casos de lesões benignas, melanoma e ceratose seborreica. Nesse artigo o diagnóstico de lesões de pele seguem um padrão, quatro propriedades são utilizadas para a identificação de melanoma na pele: assimetria, borda, cor e diâmetro. A assimetria refere-se à verificação se as duas metades do sinal combinam em termos de cor, forma e bordas. A borda verifica se as bordas do sinal são lisas e bem definidas ou irregulares. A cor avalia a variação da coloração do sinal. O diâmetro mede aproximadamente o tamanho do sinal, sendo que o melanoma geralmente possui um diâmetro maior que 6mm.

Eles tiveram resultados excelentes superando o vencedor do teste ISIC 2017 do ano anterior com uma pontuação de 97.94% e se diferenciando por terem desenvolvidos métodos de aprendizado profundo em conjunto, totalmente automáticos, que combinam dois dos melhores métodos de segmentação, o DeeplabV3+ para segmentação semântica e o Mask R-CNN para segmentação de instâncias. Esses métodos foram aplicados em diferentes conjuntos de dados de lesões de pele, mesmo com anotações de especialistas com ruídos, e produziram resultados significativamente mais precisos em comparação com métodos anteriores.

Com relação ao que pode ser melhorado, os autores citam que é possível melhorar ainda mais o desempenho dos métodos de aprendizado profundo em conjunto ao ajustar os hiperparâmetros de ambas as redes usadas. O estudo se concentra apenas em métodos de conjunto para tarefas de segmentação em conjuntos de dados de lesões de pele. No entanto, é possível aprimorar ainda mais o desempenho dos algoritmos, incluindo técnicas de pré-processamento, como a remoção de folículos capilares, e usando técnicas de aumento de dados, como o aumento natural de dados.

## 2.6 Dense Deconvolutional Network for Skin Lesion Segmentation (LI et al., 2019)

No estudo apresentado, a segmentação de lesões cutâneas é realizada através do RefineNet, treinada de ponta a ponta. A rede utiliza camadas convolucionais como uma ferramenta de extração para capturar características hierárquicas e a rede de segmentação é anexada a camadas convolucionais anteriores. A rede proposta compreende dois módulos: codificação e decodificação. O módulo de encodificação é usado para reduzir a amostra e extrair características semânticas, enquanto o módulo de decodificação é usado para expandir as características da amostra e restaurar a informação detalhada.

É sabido que múltiplas camadas são empilhadas para formar uma rede neural profunda a fim de extrair características hierárquicas. Todavia, aumentar o número de camadas da rede pode resultar no desaparecimento do gradiente ou na explosão do problema, fazendo com que dificulte a convergência no processo de treinamento. Também é provável que haja convergência para ótimos locais devido ao overfitting. Ou seja, aumentar o número de camadas, ao contrário do que muitos pensam, levará a uma queda de performance devido à maior profundidade das camadas e à degradação aparente.

Ao contrário das camadas deconvolucionais tradicionais, o método proposto adota camadas densas, mantendo as dimensões das imagens de entrada e saída. A rede é treinada dispensando conhecimentos prévios ou procedimentos de pós ou pré-processamento. Em seguida, o CRP (Chained Residual Pooling) captura informações do background e combina contextos e informações globais e locais e, por fim, a supervisão hierárquica é adicionada para atuar como perda auxiliar e para refinar a máscara de predição.

O método proposto é treinado usando uma grande quantidade de dados de treinamento, que consistem em imagens médicas de lesões cutâneas e as respectivas máscaras de segmentação. Durante o treinamento, a rede é ajustada para minimizar o erro entre as máscaras de segmentação geradas pela rede e as máscaras de segmentação de referência.

Os resultados experimentais mostraram que a abordagem proposta é capaz de superar outras abordagens de segmentação de lesões cutâneas em termos de precisão, sensibilidade e coeficiente de Dice. Além disso, a abordagem é capaz de segmentar com precisão lesões cutâneas com bordas finas e texturas finas. Em geral, o artigo apresenta uma nova abordagem promissora para a segmentação de lesões cutâneas, que pode ajudar a melhorar o diagnóstico e o tratamento de doenças de pele.

## 2.7 Automatic skin lesion segmentation with fully convolutional-deconvolution networks (YUAN, 2017)

O artigo, assim como vários outros, começa situando que o reconhecimento de melanomas conta com diversos problemas, como bordas irregulares, diferença de tamanhos e cores, falta de contraste com a cor da pele e presença de pelos e bolhas que dificultam o reconhecimento da doença. No artigo eles propõem uma estrutura baseada em redes neurais profundamente convolucionais-deconvolutivas (CDNN) para segmentar automaticamente lesões cutâneas em imagens dermatoscópicas. Deixando de focar em pré e pós processamento e investindo forças em uma boa estratégia de treinamento para o algoritmo.

Usaram como database o disponibilizado no desafio ISBI Challenge 2017, com diversas imagens em diversos contextos. Com relação a abordagem, inicialmente no que tange a arquitetura, treinaram um CDNN para mapear da imagem dermatoscópica de entrada para um mapa de probabilidade posterior. A rede contém 29 camadas com cerca de 5 milhões de parâmetros



treináveis. São utilizados o stride 1 e a função de ativação ReLU nas camadas de convolução/deconvolução, a função de ativação sigmoid na camada de saída e a normalização em lote em todas as camadas para reduzir a covariância. A estratégia de upsampling e deconvolução é utilizada para lidar com a agregação de informações em várias escalas e a classificação de pixels em resolução total, mantendo a perspectiva global das camadas de pooling.

Sobre o pré processamento eles basicamente criaram 3 outros canais além do RGB para condizer com o ratio esperado pela maioria das imagens de treinamento. Já com relação ao treinamento utilizado, treinaram a rede usando a otimização de Adam com tamanho de batch de 16 para ajustar a taxa de aprendizado com base nos momentos de primeira e segunda ordem do gradiente a cada iteração. A taxa de aprendizado inicial é definida como 0,003. Em conclusão, já no pós processamento o método utilizado foi encontrar o centro da lesão e coletar pequenas "amostras" em volta até todo o machucado estar discriminado.

As condições de pesquisa ocorreram em : Python baseado em Theano e Lasagne1. Os experimentos foram conduzidos em um desktop Dell XPS 8900 com GPU Intel (R) i7-6700 3,4 GHz e uma GPU Nvidia GeForce GTX 1060 com 6 GB de memória GDDR5. Gerando um resultado no Jaccard index de 0.784.

## 2.8 Skin Lesion Segmentation in Clinical Images Using Deep Learning (JAFARI et al., 2016)

O artigo propõe um método baseado em deep learning para segmentar lesões de pele em imagens clínicas, dividindo a imagem em duas regiões: de pele lesionada e de pele normal. Para isto, o método proposto usa quatro etapas: a de pré-processamento de imagens, a extração de patches, a segmentação usando a arquitetura uma rede neural convolucional profunda (CNN) e o pós-processamento. Na etapa de pré-processamento, as imagens são redimensionadas para um tamanho fixo e são normalizadas para aumentar o contraste e remover os ruídos das fotos. Depois, são escolhidos patches (pedaços) da imagem, que formam janelas em volta de cada pixel, de modo que ao serem alimentados em uma rede neural CNN, que rotula cada pixel central. Assim é possível obter uma análise local da imagem, sendo útil para detectar com precisão a borda da lesão. Porém, a CNN também analisa o contexto global de cada pixel, de modo a estabelecer o rótulo de de maneira consistente com o contexto da região onde o pixel está localizado.

Na etapa de segmentação, os patches são alimentados em duas CNNs paralelas, com camadas similares, uma processando o patch local e outra o patch global. Em seguida, camadas de concatenação totalmente conectadas são usadas para combinar os resultados da análise das texturas locais e globais e formar a decisão final sobre a classificação do pixel central de cada patch. Cada CNN contém quatro camadas: duas convolucionais e duas de pooling máximo. Cada camada de convolução consiste em 60 mapas de características que detectam um único tipo de recurso em toda a imagem. Já as camadas de pooling, podem facilitar o processo de aprendizado, reduzindo o número de variáveis que devem ser aprendidas na rede e ignorando a informação posicional exata dos recursos extraídos. Ao final, há uma camada totalmente conectada às duas CNNs onde ela produz a probabilidade de adesão do pixel em lesões e regiões de pele normais.

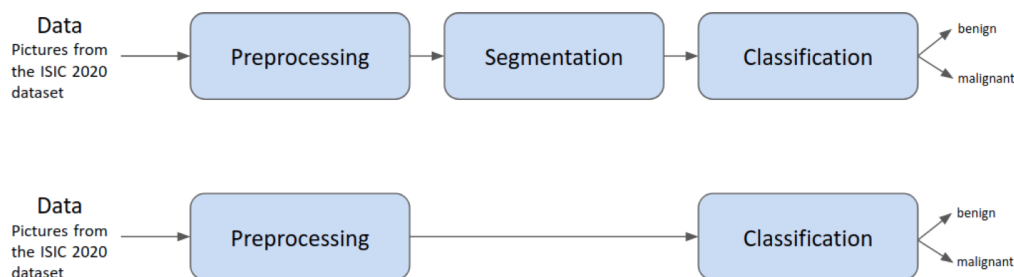
Ao fim, um mapa de segmentação é gerado, onde cada pixel recebe um rótulo indicado qual classe ele tem maior probabilidade de pertencer. Sendo 1 se o pixel for de uma lesão, e 0 se pertencer a uma região normal da pele. Ao final, a máscara de saída é refinada pela seleção do componente conectado mais extenso, assumindo-se que há apenas uma lesão em cada imagem, e por fim uma operação morfológica de preenchimento de buracos é aplicada.

O conjunto de dados usado para o treinamento e a avaliação do método proposto foi o conjunto de dados da Dermquest, disponível publicamente, que contém 126 imagens digitais, sendo 66 de melanoma e 60 de não-melanoma. O método proposto foi comparado com outros dois do estado da arte, e os resultados mostram que o método proposto supera esses métodos em termos de precisão de segmentação, alcançando alta precisão na segmentação de lesões de pele. Os resultados experimentais mostraram que o método proposto pode alcançar uma precisão muito alta de 98,5% e sensibilidade de 95,0%.

Em conclusão, a abordagem baseada em deep learning proposta para a segmentação de lesões de pele é um método promissor para segmentar com precisão lesões de pele em imagens clínicas. O método tem o potencial de ajudar no diagnóstico e tratamento do câncer de pele, fornecendo uma segmentação precisa de lesões de pele.

### 3 Modelo Proposto

Nos aprofundando em segmentação de lesões de pele, foi feito um estudo do nível de importância que tal prática, a segmentação, tem no processo de classificação de uma imagem de uma lesão de pele na detecção de um melanoma. Duas pipelines foram feitas em teste para detectar o impacto que essa transformação pode gerar, tendo em vista que o output é um binário entre: a lesão ser maligna (melanoma) e ser benigna.



#### 3.1 Dataset utilizado

O Dataset utilizado para treinar as redes neurais foi o ISIC 2020, que são basicamente 33126 imagens de lesões com alguns metadados, como sexo, idade aproximada, localização da lesão e diagnóstico médico, o dataset possui 98% das imagens benignas e 2% somente das imagens malignas e depois de augmentação (usando rotações e algumas outras transformações) esses números passaram para 12.5%

#### 3.2 Segmentação

O algoritmo K-means foi utilizado para fazer a segmentação, o k-means é usado para agrupar pixels em clusters que possuem características semelhantes, como cor, textura ou intensidade. O processo de segmentação de imagens pelo método k-means é geralmente realizado em três etapas:

1) Inicialização: O número de clusters  $k$  é definido e os centroides iniciais são escolhidos aleatoriamente. Um centroide é o ponto central de um cluster. 2) Atribuição de clusters: Cada pixel é atribuído ao cluster cujo centroide é mais próximo. A distância entre cada pixel e cada centroide é calculada usando alguma métrica, como a distância Euclidiana. 3) Atualização

dos centroides: Uma vez que todos os pixels foram atribuídos a um cluster, os centroides são atualizados para refletir a média dos pixels em cada cluster.



### 3.3 Classificação

Para a tarefa de classificação, foi usado EfficientNet B0 pré-treinada em ImageNet sem as camadas densas no final, que foram substituídas por uma camada densa conectada a um único nó com a função de ativação sigmoid, para que o modelo produza uma probabilidade de que a imagem de entrada seja maligna. A função sigmoid é frequentemente usada para produzir uma saída de probabilidade entre 0 e 1. Isso é útil para tarefas de classificação binária, como determinar se uma imagem é maligna ou benigna. Quando a saída da função sigmoid é 0.5 ou superior, é provável que a imagem seja maligna, e quando a saída é inferior a 0.5, é provável que a imagem seja benigna.

Além disso foi adicionado um GlobalAveragePooling2D antes da última camada densa, o pooling global de média é uma técnica de pooling que calcula a média dos valores de cada canal de recurso em uma camada convolucional. Essa técnica reduz a dimensionalidade dos recursos de uma imagem para um vetor de tamanho fixo, independentemente do tamanho da imagem de entrada.

Ademais, dois callbacks foram adicionados ao model antes de fazer seu fit, o earlyStopping que é usado para interromper o treinamento da rede neural quando uma determinada métrica não melhora mais depois de um certo número de épocas; já o ReduceLROnPlateau é usado para reduzir a taxa de aprendizagem da rede neural quando uma determinada métrica não melhora mais depois de um certo número de épocas.


## 4 Experimentos

2 Experimentos ao total foram realizados para verificar a necessidade da segmentação para classificação de imagens de lesão em benignas e malignas: (1) Treinamento usando segmentação, (2) Treinamento sem segmentação


Os modelos foram treinados em um MacBook Pro, sistema operacional: macOS Monterey versão 12.6.3, 2 GHz Intel Core i5 Quad-core, 16GB de ram 3733 MHz. Batch size de 256 e 35 epochs com 8000 imagens do dataset.

A acurácia encontrada no modelo sem segmentação foi de 96,38%





A acurácia encontrada no modelo com segmentação foi de 95,93%



Em conclusão, observamos que a acurácia proveniente da validação utilizando lesões previamente segmentadas foi ligeiramente inferior em relação às imagens não segmentadas. Essa diferença pode estar atrelada à técnica utilizada para segmentar as imagens, ou à hipótese de que o contraste entre a lesão e a pele saudável também é um fator importante para a assertividade do diagnóstico.

## Referências

- GOYAL, Manu et al. Skin lesion segmentation in dermoscopic images with ensemble deep learning methods. **IEEE Access**, IEEE, v. 8, p. 4171–4181, 2019.
- JAFARI, M.H. et al. Skin lesion segmentation in clinical images using deep learning. In: 2016 23rd International Conference on Pattern Recognition (ICPR). [S.l.: s.n.], 2016. P. 337–342. DOI: 10.1109/ICPR.2016.7899656.
- LI, Hang et al. Dense Deconvolutional Network for Skin Lesion Segmentation. **IEEE Journal of Biomedical and Health Informatics**, v. 23, n. 2, p. 527–537, 2019. DOI: 10.1109/JBHI.2018.2859898.
- AL-MASNI, Mohammed A et al. Skin lesion segmentation in dermoscopy images via deep full resolution convolutional networks. **Computer methods and programs in biomedicine**, Elsevier, v. 162, p. 221–231, 2018.
- TANG, Peng et al. Efficient skin lesion segmentation using separable-Unet with stochastic weight averaging. **Computer methods and programs in biomedicine**, Elsevier, v. 178, p. 289–301, 2019.
- ÜNVER, Halil Murat; AYAN, Enes. Skin lesion segmentation in dermoscopic images with combination of YOLO and grabcut algorithm. **Diagnostics**, Mdpi, v. 9, n. 3, p. 72, 2019.
- YUAN, Yading. Automatic skin lesion segmentation with fully convolutional-deconvolutional networks. **Department of Radiation Oncology**, p. 1–4, 2017.
- YUAN, Yading; CHAO, Ming; LO, Yeh-Chi. Automatic skin lesion segmentation using deep fully convolutional networks with jaccard distance. **IEEE transactions on medical imaging**, IEEE, v. 36, n. 9, p. 1876–1886, 2017.